

# DM2FNet 去雾模型实践与改进

张鑫 21307130295

2024 年 5 月 30 日

## 1 摘要

单图像去雾任务逐渐成为近年来的研究焦点。Deng 等人提出的 DM2FNet 模型 [2] 在雾天图像退化模型的基础上，以层分离模型的去雾图像作为补充，在单图像去雾任务上取得了显著提升，但仍然存在细节模糊、色彩失真、光斑等图像去雾的经典问题，不能有效泛化到不同可见度的含雾图像。本文基于 DM2FNet 展开对单图像去雾任务的实践与改进，能够在一定程度上缓解 DM2FNet 存在的色彩失真等问题，提高 DM2FNet 处理不同可见度的含雾图像的能力。本文实践所用的代码见[源码](#)，模型权重见[权重](#)，提取码：dipp。

## 2 背景

### 2.1 图像去雾概述

图像去雾是通过算法，将受到天气、拍摄条件等影响得到的含雾图像，恢复成清晰图像的过程。受到大气中各种微粒的影响，在雾天拍摄的图片通常质量极差。这不仅会影响人眼的视觉体验，对于计算机视觉领域而言，更会对图像分类、目标检测等依赖清晰图片的任务造成干扰。在安防监控、自动驾驶等一些实际应用场景中，图像去雾更是保证整个系统稳定性的关键。因此，近年来，图像去雾越来越受到研究者的广泛关注。

### 2.2 去雾方法综述

一般而言，图像去雾算法主要可分为三类：基于图像增强、基于图像复原、基于深度学习。

#### 2.2.1 基于图像增强的去雾算法

此类算法将雾作为图像噪声，通过增强对比度和图像细节来恢复出清晰图像。代表性方法有：

- **Retinex 算法**：基本原理是增强局部对比度，恢复图像细节。该算法假设图像由反射分量和照明分量两个部分组成。反射分量反映细节信息，照明分量反映全局光照。通过估计光照分量分解出反射分量，减少光照不均来实现更好的去雾效果。
- **直方图均衡化**：其基本思想也是增强图像对比度，但通过对像素强度进行重新分配来实现。直方图均衡化可以更好地分离出雾气和场景，实现更好的去雾效果。

#### 2.2.2 基于图像复原的去雾算法

此类方法基本是基于雾天图像退化模型 (atmospheric scattering model, AS Model)：

$$I(p) = J(p)T(p) + A(p)(1 - T(p))$$

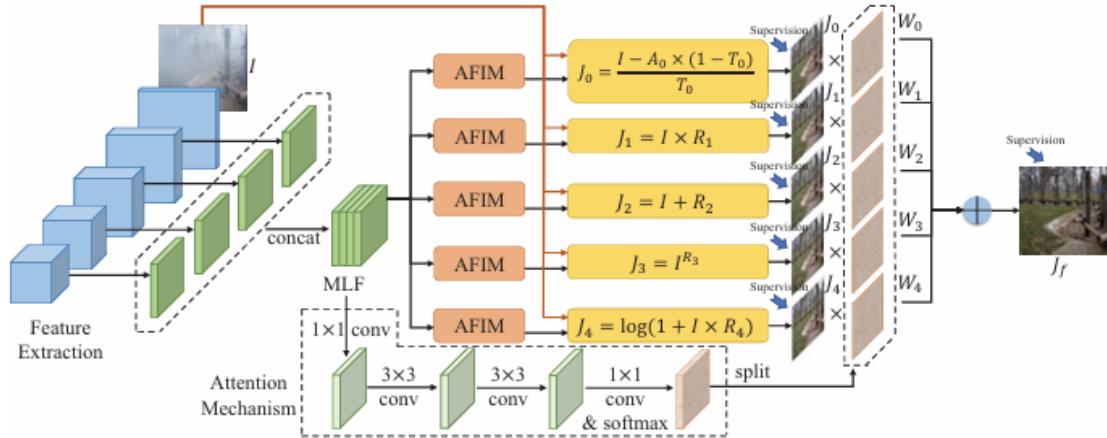


图 1: DM2FNet 整体结构

在这个模型中,  $I(p)$  表示观察到的图像,  $J(p)$  表示对应的无雾图像,  $A(p)$  表示全局大气光,  $T(p)$  表示透射率。基于此模型的算法, 一般都是根据已知的雾天图像  $I(p)$  来求解透射率  $T(p)$  和大气光  $A(p)$ , 进而还原出无雾图像。

最具代表性的方法就是何凯明博士的暗通道去雾算法 [4], 基于暗通道先验来估计图像的透射率和大气光, 将含雾图像中恢复出清晰图像。

### 2.2.3 基于深度学习的去雾算法

得益于深度学习为计算机视觉带来的巨大进步, 基于深度学习的去雾模型也不断被提出。一些深度学习模型同样依赖雾天图像退化模型, 通过深度学习的方法估计透射率  $T(p)$  和大气光  $A(p)$ 。而另一些深度学习模型采用端到端的方法, 直接从含雾图像生成无雾图像。在扩散模型被提出后, 也有通过扩散模型来补全含雾图像中损失的信息的方法被不断提出 [9], 去雾模型的去雾效果也不断得到提升。

## 2.3 图像去雾难点

图像去雾主要存在以下几个难点:

- 建模困难:** 图像中雾的形成是一个及其复杂的物理过程, 不仅会受到天气、光照、大气微粒数等自然条件的影响, 拍摄者的设备、角度等也会导致图像的产生“雾化”效果。难以用统一的模型对图像中雾的形成进行建模分析。
- 效果不稳定, 易产生细节模糊和色彩失真:** 图像中的雾化区域损失了材质、色彩、边缘细节等基本信息, 因此一些算法产生的去雾图像与原图相比, 会出现色彩失真、细节模糊等问题, 效果不稳定。
- 真实的数据集难以获取, 模型泛化困难:** 对于基于深度学习的去雾算法而言, 在合成的数据集上进行训练得到的模型, 效果难以泛化到真实拍摄的图片。但是在真实的场景下, 受限于拍摄角度、含雾与不含雾场景的一致性等条件的约束, 想要获取高质量的图像去雾的数据集耗时费力。

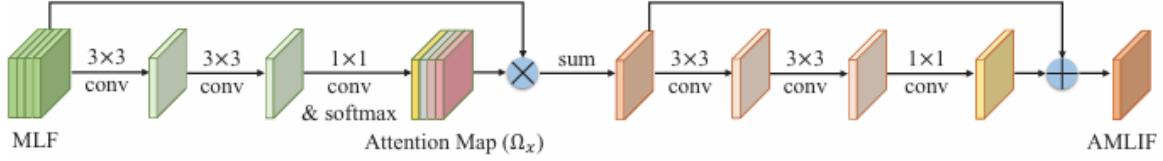


图 2: AFIM 模块

### 3 方法介绍

DM2FNet 是由 Deng 等人提出的深度神经网络，是一种通过融合雾天图像退化模型的结果，和“端到端”式层分离模型的结果来进行图像去雾的方法，在多个数据集上超越了此前很多模型的表现。我以 DM2FNet 作为 Baseline 算法，并在其之上进行改进。

#### 3.1 DM2FNet 介绍

DM2FNet 的整体模型和关键模块如图1、图2所示，主要有两个特点：

##### 3.1.1 提出了 Attentional Feature Integration Module(AMLIF) 进行更优的特征提取

CNN 模型的浅层擅长提取细节信息，但是缺少全局的语义信息。基于浅层特征进行去雾，虽然会注意到含雾区域的更多细节信息，但是也会导致无雾区域的细节被去雾过程破坏。

CNN 模型的深层擅长提取语义信息，但是缺少细节信息。基于深层特征进行去雾，虽然能够去除大部分的含雾区域，但是会因为缺少局部细节信息而导致色彩失真等问题。

因此，Baseline 算法通过注意力机制来进行浅层和深层特征的融合，综合浅层和深层特征的优点来增强去雾效果。

##### 3.1.2 图像复原和图像融合思想的结合

Baseline 算法提出了 4 个“端到端”的层分离模型，认为这些模型学习到的信息，可以作为雾天图像退化模型的补充。通过注意力机制进行加权融合，来提升最终的去雾性能。

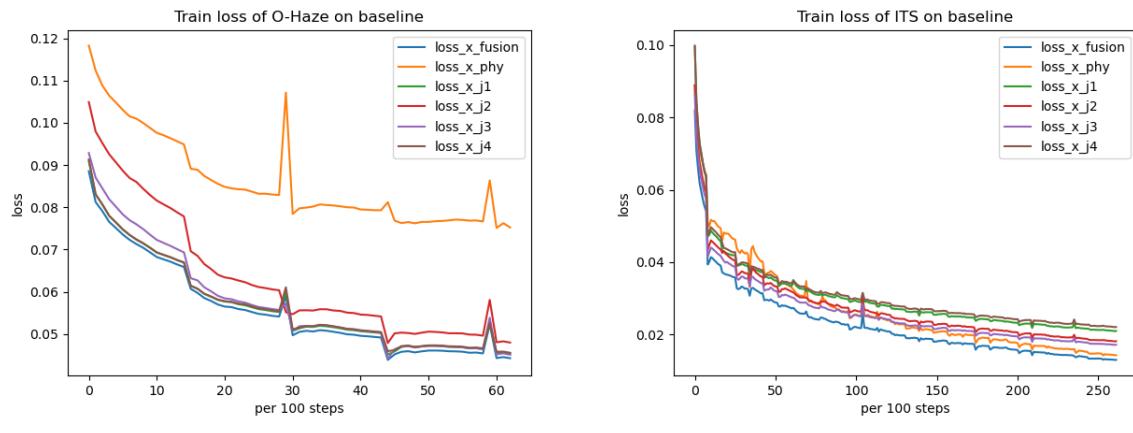


图 3: Baseline 训练损失曲线

## 3.2 改进方法介绍

### 3.2.1 由 O-Haze 数据集 [1] 诱导的改进

Baseline 算法在 O-Haze 数据集上已经取得了优越的表现，但如图4(c)所示，仍然存在较明显的色彩失真。



图 4: O-Haze 数据集上的 Baseline 算法与改进算法对比

如图3，对训练结果分析发现，层分离模型的 loss 低于大气散射模型的 loss，这表现为大气散射模型的指标低于层分离模型。但是在 RESIDE-ITS 数据集 [6] 上，大气散射模型的 loss 最低，指标最高。这可能是因为相比于 RESIDE-ITS 数据集，在 O-Haze 数据集上，没有  $a$ (大气光) 和  $t$ (透射率) 的监督信息，导致大气散射模型表现不佳。

基于此出发点，为了解决这一问题，我引入了 Li、Peng 等人提出的 Reformatted AS Model(RASM)[5]。

$$J(p) = K(p)I(p) - K(p) + b, \text{ where}$$

$$K(p) = \frac{\frac{1}{T(p)}(I(p) - A) + (A - b)}{I(p) - 1}$$

RASM 重写了 AS Model 的公式。因为 O-Haze 数据集没有  $a$  和  $t$  的信息监督，所以我引入它的目的是：通过避免分别学习  $a$  和  $t$ ，来减少训练过程对  $a$  和  $t$  的监督信息的依赖。但是为了兼顾如 RESIDE-ITS 这类有  $a$  和  $t$  的监督信息的数据集，我没有完全用 RASM 替换掉 AS Model，而是沿用 Baseline 图像融合的思想，分别用 RASM 和 AS Model 预测，用一个 Mix 模块将二者的结果进行加权混合，作为雾天退化模型模块的输出结果。这个 Mix 模块也是可训练的，因此无论数据集有没有  $a$  和  $t$  的监督信息，通过训练，总是能选择更优的结果。这样处理之后能够提高在 O-Haze 数据集上的表现，一定程度上缓解色彩失真。

### 3.2.2 由 HazeRD 数据集 [10] 诱导的改进

Baseline 算法在 HazeRD 数据集上存在的主要问题是：不能将去雾效果泛化到浓雾天气的图像。这是因为在浓雾条件下，图像丢失的细节信息更多，不同深度的透射率直接差距较大，造成图像去雾的困难。在 RESIDE-ITS 数据集上进行训练得到的模型，在可见度较低时，甚至会产生严重的白色光斑。

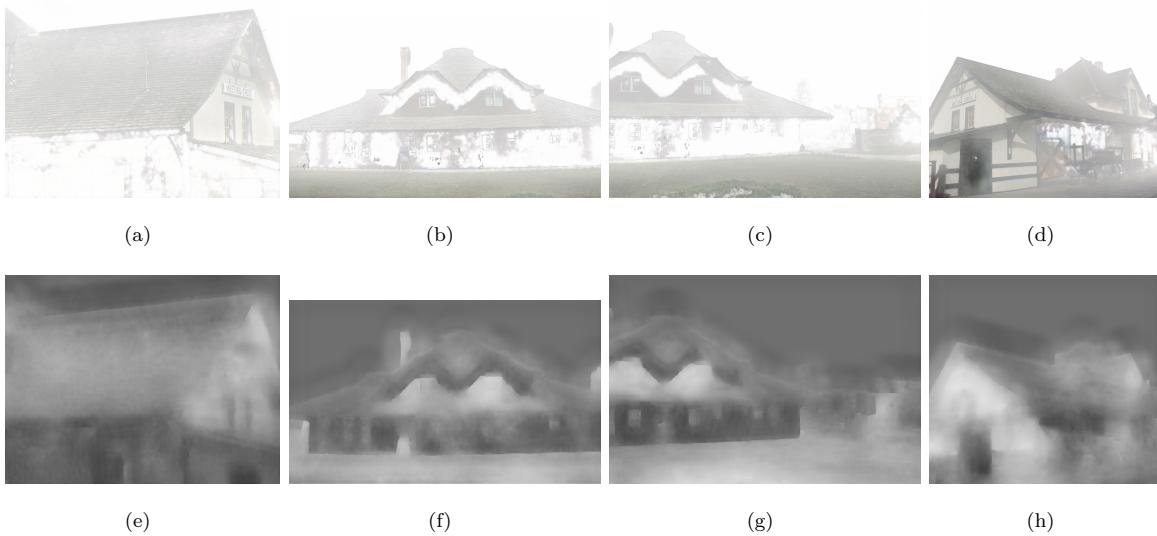


图 5: HazeRD 数据集上能见度 50m, Baseline 算法产生严重白色光斑

为什么是白色光斑而不是其它其他颜色的光斑？首先我们分析一下透射率与像素深度的关系：根据 AS Model，透射率  $t$  应该随着深度增大而衰减。基于这个性质，在这些出现明显光斑的数据中，我对 Baseline 模型预测的  $a$  和  $t$  进行了可视化分析，见图5。

通过可视化我注意到，出现白色光斑的区域的透射率很低，但其实这些区域相对于深度最深的背景色而言，其实际透射率应该比这些背景色处的透射率高。这就说明，出现白色光斑的原因是，Baseline 模型对于某些深度较小的点预测出的透射率比实际偏小，根据 AS Model，导致全局光照的比例增大，进而在逆向恢复过程中产生白色光斑。

除了上述原因，我还分析了 Baseline 算法的损失函数的设计对模型性能造成的影响。由于 Baseline 算法将各个模型预测结果的 loss 简单加权求和，根据梯度反向传播的原理，各个 loss 反向传播的初始梯度都是“1”，导致 AS Model 中预测  $t$  的模块的初始梯度具有各向同性。这种各向同性可能导致模型不能很好地关注到不同像素点之间的深度区别，导致深度较浅的像素点预测出的透射率比实际偏小的可能性增大。

针对这种各向同性，我在 DM2FNet 的 Multi-level-feature 的提取过程中引入了 Qin、Wang 等人提出的 ChannelAttention 和 PixelAttention 机制 [7]。这种机制可以更好地对不同像素和通道进行特征融合，能够减小不同深度的像素预测出相同透射率的倾向。

同时，为了解决初始梯度为“1”的各向同性，我在 DM2FNet 的训练过程中增加了一个表现优良的图像恢复模型 TSNet-t2[3]，称之为 Helper Network。将 DM2FNet 生成的去雾结果输入到 Helper Network 中进行恢复之后再计算 loss，可以为 DM2FNet 中的 AS Model 模块提供一个不具有各向同性的初始梯度，从根本上消除了这种各向同性。

在损失函数方面我也做了一些改进。我提出了 ReconstructLoss，具体做法是利用预测出的  $a$  和  $t$ ，根据 AS Model 从清晰图像生成雾化图像，与真实的雾化图像之间进行一次 L1Loss。这样可以加强对  $a$  和  $t$  的学习。同时引入了 Wu、Qu 等人提出的 Contrastive Learning 思想 [8]，对损失函数进行了进一步强化。

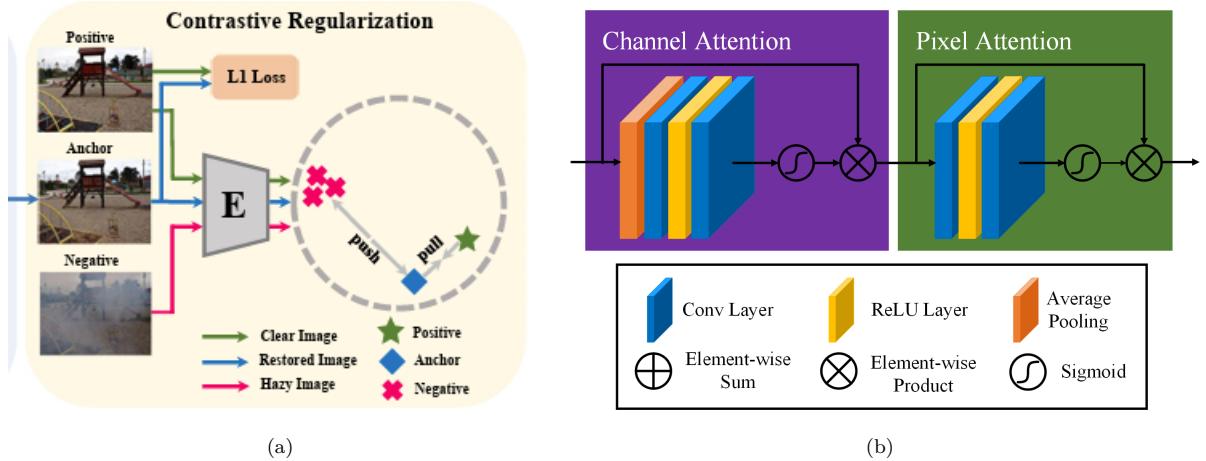


图 6: 左: Contrastive Learning, 右: ChannelAttention&PixelAttention

## 4 实验介绍

### 4.1 数据集介绍

实验主要在 O-Haze 数据集、RESIDE 数据集和 HazeRD 数据集上进行。

对于 O-Haze 数据集, 共 45 组图片, 将前 35 组图片裁剪为  $512 \times 512$  后作为训练集, 剩余的 10 组图片不进行裁剪, 前 4 张作为验证集, 后 6 张作为测试集。

对于 HazeRD 数据集, 其图片数量较少。使用 RESIDE-ITS 作为训练集, RESIDE-SOTS 作为验证集, HazeRD 作为测试集。

### 4.2 实验设置介绍

实验使用一张 RTX 3090(24GB) 显卡开展。

对于 Baseline 算法使用 DM2FNet 的作者提供的参数进行训练。

对于改进算法, 在 O-Haze 数据集上仅使用 ReconstructLoss 和 Reformatted AS Model; 在 HazeRD 数据集上使用 Contrastive Learning 和 ReconstructLoss 增强 loss, 同时使用融入了 ChannelAttention 和 PixelAttention 机制的特征提取模块。

### 4.3 指标介绍

本实验主要使用以下 4 种指标:

- **MSE(Mean Squared Error, 均方误差)**: 该指标从数值上衡量图像之间的差异程度。值越小表示两幅图像之间的差异越小。对于本实验而言, 该值越小, 表示去雾效果越好。
- **PSNR(Peak Signal-to-Noise Ratio, 峰值信噪比)**: 该指标是另一种衡量图像质量的常用指标, 其数值越高表示图像质量越好。对于本实验而言, 该值越大, 表示去雾效果越好。
- **SSIM(Structural Similarity Index, 结构相似性指数)**: 该指标更加注重图像的结构信息和人眼感知的相似性, 是一种综合亮度、对比度、结构等信息的综合性指标。越接近于 1, 表示效果越好。对于本实验而言, 该值越大, 表示去雾效果越好。

- **CIEDE2000(CIE Delta E 2000)**: 该指标用于衡量图像之间的颜色差异, 值越小表示越色差越小。对于本实验而言, 该指标用于衡量色彩失真的程度, 值越小, 表示去雾效果越好。

#### 4.4 实验结果指标

表 1: O-Haze 数据集上的结果指标

| Method   | MSE             | PSNR             | SSIM            | CIEDE2000       |
|----------|-----------------|------------------|-----------------|-----------------|
| Baseline | 0.004154        | 24.087323        | 0.752308        | 5.799282        |
| Enhanced | <b>0.003147</b> | <b>25.169492</b> | <b>0.765734</b> | <b>4.965465</b> |

表 2: HazeRD 数据集上的结果指标

| Method   | MSE             | PSNR             | SSIM            | CIEDE2000        |
|----------|-----------------|------------------|-----------------|------------------|
| Baseline | 0.071781        | 14.379280        | 0.621081        | 15.963133        |
| Enhanced | <b>0.064638</b> | <b>14.898777</b> | <b>0.631876</b> | <b>14.714860</b> |

可以看到, 在 O-Haze 数据集和 HazeRD 数据集上, 改进算法的指标均优于 Baseline 算法。特别是在 CIEDE2000 这一指标上, 改进算法提升明显, 这说明我提出的改进模型和 helper 训练方式能够有效地减小去雾图像的色差。

#### 4.5 结果样例介绍

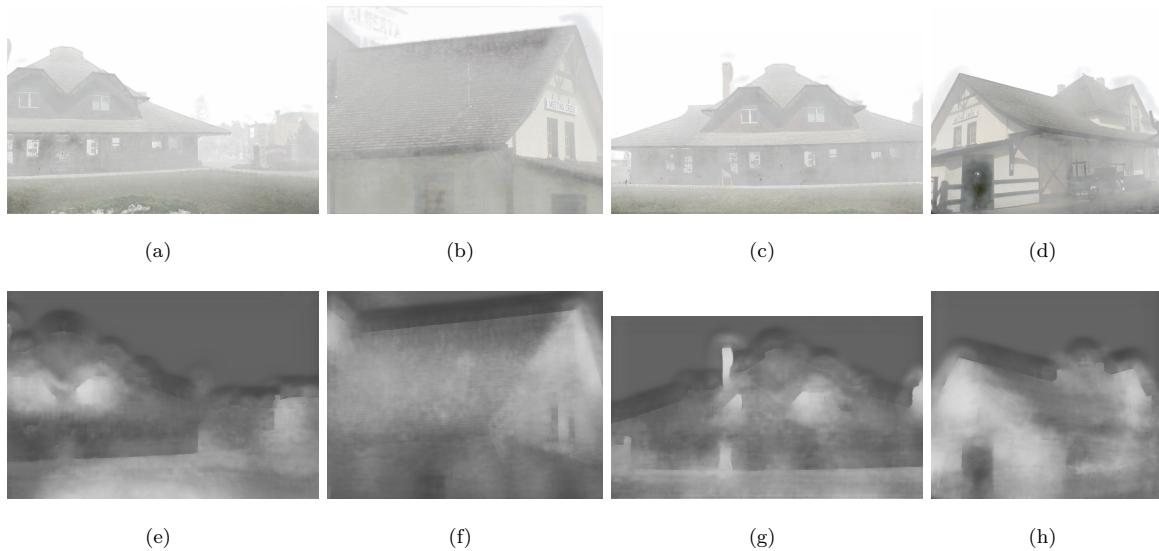


图 7: HazeRD 数据集上能见度 50m, 改进算法消除了大部分白色光斑

可以看到, 相比于 Baseline 算法, 改进算法能够更好地估计透射率  $t$ , 不容易导致深度小的像素处产生较低的透射率, 很好地消除了图像的光斑化。这进一步证实了前文中的分析。

#### 4.6 自己收集的图片的去雾样例

自行在社交平台收集了五张含雾图像, 用 Baseline 模型和改进算法的模型进行去雾的结果如下:



(a)

(b)

(c)

图 8: Hazy, Baseline, Enhanced



(a)

(b)

(c)

图 9: Hazy, Baseline, Enhanced

## 5 结论与感悟

本文通过对 Baseline 算法的实践和改进，探索了如何有效地消除能见度低的情况下雾图像中的光斑。利用 Contrastive Learning 等思想改进损失函数，提出了利用 helper 网络改变初始梯度的各向同性的训练方式，能够有效地消除雾图像中的光斑，预测更符合物理模型的透射率。在探索的过程中，我深深体会到要有方向性地去开展实验的重要性，科研思维得到了锻炼。

## 参考文献

- [1] Codruta O Ancuti, Cosmin Ancuti, Radu Timofte, and Christophe De Vleeschouwer. O-haze: a dehazing benchmark with real hazy and haze-free outdoor images. In *Proceedings of the IEEE conference on computer vision and pattern recognition workshops*, pages 754–762, 2018.
- [2] Zijun Deng, Lei Zhu, Xiaowei Hu, Chi-Wing Fu, Xuemiao Xu, Qing Zhang, Jing Qin, and Pheng-Ann Heng. Deep multi-model fusion for single-image dehazing. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 2453–2462, 2019.
- [3] Xiaolin Gong, Zehan Zheng, and Heyuan Du. Tsnet:a two-stage network for image dehazing with multi-scale fusion and adaptive learning, 2024.
- [4] Kaiming He, Jian Sun, and Xiaoou Tang. Single image haze removal using dark channel prior. *IEEE transactions on pattern analysis and machine intelligence*, 33(12):2341–2353, 2010.
- [5] Boyi Li, Xiulan Peng, Zhangyang Wang, Jizheng Xu, and Dan Feng. Aod-net: All-in-one dehazing network. In *Proceedings of the IEEE international conference on computer vision*, pages 4770–4778, 2017.



(a)

(b)

(c)

图 10: Hazy, Baseline, Enhanced



(a)

(b)

(c)

图 11: Hazy, Baseline, Enhanced

- [6] Boyi Li, Wenqi Ren, Dengpan Fu, Dacheng Tao, Dan Feng, Wenjun Zeng, and Zhangyang Wang. Benchmarking single-image dehazing and beyond. *IEEE Transactions on Image Processing*, 28(1):492–505, 2018.
- [7] Xu Qin, Zhilin Wang, Yuanchao Bai, Xiaodong Xie, and Huizhu Jia. Ffa-net: Feature fusion attention network for single image dehazing, 2019.
- [8] Haiyan Wu, Yanyun Qu, Shaohui Lin, Jian Zhou, Ruizhi Qiao, Zhizhong Zhang, Yuan Xie, and Lizhuang Ma. Contrastive learning for compact single image dehazing, 2021.
- [9] Hu Yu, Jie Huang, Kaiwen Zheng, and Feng Zhao. High-quality image dehazing with diffusion model, 2024.
- [10] Yanfu Zhang, Li Ding, and Gaurav Sharma. Hazerd: an outdoor scene dataset and benchmark for single image dehazing. In *2017 IEEE international conference on image processing (ICIP)*, pages 3205–3209. IEEE, 2017.

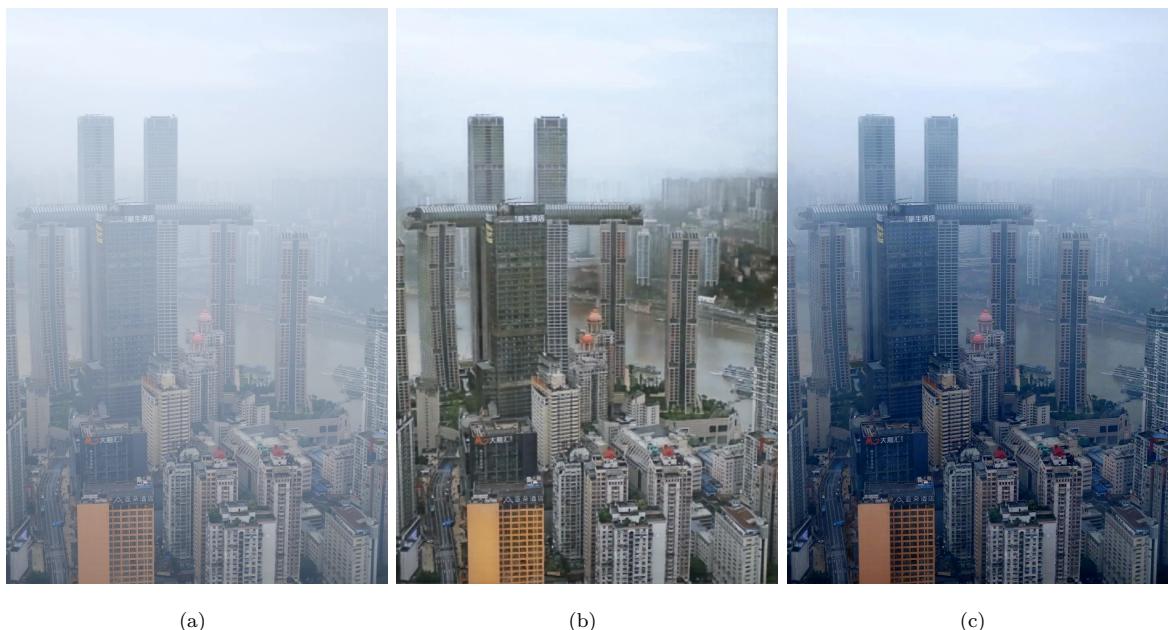


图 12: Hazy, Baseline, Enhanced